

03 · Lendo o Judge Revisor

Capa — Lendo o Judge Revisor

Capa — Lendo o Judge Revisor

03 · Lendo o Judge Revisor

Trilha Agente · 30 minutos · Pré-requisito: 02-Disparando no WhatsApp

Por Equipe Nexus · Academ'IA

Nexus Affil'IA'te · 2026

Sobre este curso

O Judge Revisor é o componente mais importante para a sua segurança operacional. Ele é o que te protege de ban do WhatsApp, de multas da LGPD, e de mensagens com tom inadequado. Em 30 minutos, você vai entender como ele funciona, como configurar as regras, como interpretar os vereditos (verde/amarelo/vermelho), e como calibrá-lo ao longo do tempo. Para a interface detalhada, consulte a tela [\[7\]](#) [dashboard/judge](#) ou a **Apostila 05** (Tela 04).

Sumário

- 1. O que é o Judge Revisor • 2. Como ele funciona tecnicamente • 3. Os 3 vereditos • 4. As 5 categorias de revisão • 5. Configurando as regras • 6. Whitelist e Blacklist • 7. Lendo as reprovações • 8. Calibrando o Judge ao longo do tempo • 9. Quando desativar (raramente) • 10. Próximo curso

1. O que é o Judge Revisor

O Judge Revisor é um **LLM menor (3B parâmetros)**, afinado especificamente para revisar saídas do seu agente antes de virarem ação. Ele é o filtro final.

Por que ele existe?

- LLMs grandes (como o que gera copy) podem produzir texto que viola compliance sem perceber.
- O Judge é uma **segunda opinião** automática, sem custo de tempo.
- Ele aprende com o feedback humano (calibração).

2. Como ele funciona tecnicamente

Para cada mensagem gerada pelo copywriter, o Judge:

1. **Lê o texto** e o contexto de uso.
2. **Aplica 5 categorias de revisão** (próxima seção).
3. **Calcula um score** de 0-1.
4. **Emite um veredito** baseado no score e nas regras configuradas.
5. **Registra** a decisão no log.

Latência típica: 200-500ms por mensagem. Para 1.000 mensagens, ~5 minutos.

3. Os 3 vereditos

Aprovado - Score > 0.85. - Mensagem segue sem ressalvas. - Selo verde no log.

• **Alerta** - Score 0.5-0.85. - Mensagem segue, mas fica marcada para revisão humana. - Aparece em `/dashboard/judge` como “revisar”.

Bloqueado - Score < 0.5. - Mensagem **não é enviada**. - Requer aprovação manual.

4. As 5 categorias de revisão

Categoria 1 — LGPD (peso: alto) - Verifica: tem consentimento? menciona coleta de dados? pede dados sensíveis? - Bloqueia: mensagens sem contexto de consentimento, pedido de CPF/senha, etc. - Configurável em: templates (“Conservador LGPD”, “Permissivo”, “Custom”).

Categoria 2 — Spam (peso: alto) - Verifica: palavras-gatilho (“GRÁTIS”, “URGENTE”, “CLIQUE AGORA”)? repetição de exclamação? caps excessivo? - Bloqueia: copy com > 2 palavras-gatilho, caps > 30% do texto, > 3 exclamações.

Categoria 3 — Claim médico/saúde (peso: alto) - Verifica: promete cura? usa linguagem absoluta (“100% eficaz”, “garantido”)? - Bloqueia: claims sem evidência científica, promessas absolutas.

Categoria 4 — Tom (peso: médio) - Verifica: agressivo? desrespeitoso? passivo-agressivo? inapropriado? - Bloqueia ou alerta conforme configuração.

Categoria 5 — Personalização (peso: baixo) - Verifica: tem nome do lead? contexto pessoal? - Alerta (não bloqueia) mensagens genéricas.

5. Configurando as regras

Caminho: `/dashboard/judge/config`

Modo de operação: •

- **Bloqueio Total:** qualquer reprovação = bloqueia. Recomendado para iniciantes.
- **Alerta:** reprovação = alerta (envia, mas marca). Para afiliados experientes.
- **Permissivo:** só bloqueia violações graves. Para cenários de baixo risco.

Regras habilitadas (todas recomendadas):

- LGPD: bloqueio.
- Spam: bloqueio.
- Claim médico: bloqueio.
- Tom: alerta (não bloqueia).
- Personalização: alerta (não bloqueia).

6. Whitelist e Blacklist

Whitelist: termos autorizados. O Judge **não** vai reprovar mensagens que contenham esses termos. - Exemplo: nome do seu produto ("Curso de Copy"), nome do seu mentor, slogans da marca.

Blacklist: termos proibidos. O Judge **vai reprovar** mensagens com esses termos. - Exemplo: nomes de concorrentes, termos ofensivos, promessas proibidas pelo seu produto.

Como adicionar: simplesmente cole os termos em `/dashboard/judge/lists` (uma por linha, ou CSV).

7. Lendo as reprovações

Vá em `/dashboard/judge` para ver o histórico:

Cada reprovação mostra: - Mensagem original. - Categoria reprovada (LGPD, spam, etc.). - Motivo específico (“Contém ‘GRÁTIS’ em 3+ ocorrências”). - Score. - Sugestão de reescrita (gerada pelo Judge).

Como agir:

- **Se concorda com a reprovação:** descarte a mensagem, ajuste a copy.
- **Se discorda:** adicione o termo à whitelist ou ajuste a regra.

8. Calibrando o Judge ao longo do tempo

Mês 1: deixe em Bloqueio Total. Não mexa nas regras.

Mês 2: analise as reprovações. Se Judge está reprovando mensagens legítimas (> 10%), ajuste a whitelist.

Mês 3: considere mudar para modo “Alerta” se você já entendeu os padrões.

Mês 6+: ajuste fino por categoria (mais tolerante em tom, mais rigoroso em LGPD).

Como medir calibração:

- Reprovações > 20% das mensagens: Judge muito rigoroso.
- Reprovações < 3%: Judge pode estar frouxo.
- Taxa de banimento: 0% (se > 0, Judge não está protegendo o suficiente).

9. Quando desativar (raramente)

Desative apenas em:

- Ambiente de teste (não produção).
- Debug de copy (quer ver exatamente o que o agente gera).

- Cenário de altíssima confiança com Judge temporariamente sobre-revisando.

Nunca desative em produção, mesmo que “seja só hoje”.
Banimento não avisa antes.

10. Próximo curso

Você completou a **Trilha Agente**. Próximo passo:

`../master/00-otimizacao-conversao.md` — Otimização de Conversão · 45 min

O que você vai aprender na trilha Master: - Otimizar funis com base em coortes. - A/B test rigoroso com Judge. - Análise de churn e retenção. - Reduzir CAC, aumentar LTV.

Recursos extras: - **Apostila 05:** 7 Telas Essenciais (deep dive na Tela 04 - Judge). - **Apostila 08:** Rotina de Disparo (como revisar Judge todo dia). - **Apostila 09:** Campanhas Automatizadas (modelos testados).

03 · Lendo o Judge Revisor — Trilha Agente

MMN AI-to-AI · 2026 · Todos os direitos reservados · Licença:
CC BY-SA 4.0