

01 · Entendendo o IOAID

Capa — Entendendo o IOAID

Capa — Entendendo o IOAID

01 · Entendendo o IOAID

Trilha Fundamental · 20 minutos · Pré-requisito: 00-Boas-vindas

Por Equipe Nexus · Academ'IA

Nexus Affil'IA'te · 2026

Sobre este curso

Agora que você conhece o ecossistema, é hora de descer um nível e entender o coração técnico de tudo: o **IOAID** (Infraestrutura Operacional de Inteligência Distribuída). Em 20 minutos, você vai entender o que é o IOAID, como ele processa cada requisição, e como usar isso para tomar melhores decisões como afiliado. Não precisa ser programador — apenas curioso.

Sumário

- 1. O que é IOAID em uma frase
- 2. Por que “distribuída”?
- 3. Os 5 módulos do IOAID
- 4. O fluxo completo de uma requisição
- 5. Como o IOAID conversa com seu agente
- 6. O papel do Judge

Revisor • 7. Autenticação e segurança • 8. Latência e SLA: o que esperar • 9. Como o IOAID impacta sua operação diária • 10. Próximo curso

1. O que é IOAID em uma frase

IOAID é o sistema que pega uma intenção sua (“quero disparar mensagem de Natal para meus 800 contatos frios”) e a executa de forma auditável, escalável, e reversível.

Três palavras-chave: **auditável** (você sabe o que foi feito), **escalável** (funciona com 10 ou 10.000 contatos), **reversível** (você pode desfazer ações problemáticas).

2. Por que “distribuída”?

A palavra “distribuída” não é marketing. É uma decisão técnica com implicações:

- **Sem ponto único de falha:** se um nó cai, os outros continuam. Você não fica offline porque o servidor central caiu.
- **Latência local:** requisições são processadas no seu nó, não em datacenter distante. Resultado: < 2s para 95% das ações.
- **Privacidade:** seus dados de lead ficam no seu nó. Você tem controle total.
- **Escala horizontal:** adicionar mais afiliados = adicionar mais nós = mais capacidade global.

3. Os 5 módulos do IOAID

O IOAID é organizado em 5 módulos, cada um com responsabilidade única:

M1 — Ingestion (Recepção) - Recebe requisições externas: webhooks, APIs, comandos do painel. - Valida autenticação (token, mTLS). - Valida parâmetros (formato, ranges). - Devolve um `request_id` único para rastreamento. - Latência média: 50-100ms.

M2 — Routing (Roteamento) - Decide qual agente/skill deve processar. - Lê o `skill-manifest.json` para entender capacidades. - Encadeia skills quando necessário. - Define fallback se a skill primária falhar. - Latência média: 50-200ms.

M3 — Execution (Execução) - Roda a skill em **sandbox isolado** (memória, CPU, network restritos). - Captura todos os side-effects. - Aplica timeout (default 30s). - Mata loops infinitos automaticamente. - Latência média: 200ms-15s (depende da skill).

M4 — Persistence (Persistência) - Registra input, decisão, output, custo, latência. - Alimenta telemetria (Métricas + Logs + Traces). - Permite replay de qualquer execução. - Mantém log de custódia (auditável). - Latência média: 100-500ms.

M5 — Response (Resposta) - Devolve o resultado com metadados. - Inclui selo de aprovação do Judge. - Inclui log de custódia para compliance. - Notifica webhook (se configurado). - Latência média: 50-100ms.

4. O fluxo completo de uma requisição

Vamos acompanhar um disparo de WhatsApp, do clique ao envio:

Passo 1: Você clica “Disparar Natal” no painel.

Passo 2: Painel envia `POST /api/v1/dispatch` para M1 (Ingestion). - Token validado ✓ - Parâmetros validados (mensagem, base, agendamento) ✓ - `request_id = req_a8f3e2c1` devolvido.

Passo 3: M2 (Routing) decide. - Lê `whatsapp-sender` no skill-manifest. - Identifica: precisa de `audience-segmenter` + `copy-personalizer` + `whatsapp-sender`. - Encadeia.

Passo 4: M3 (Execution) executa. - `audience-segmenter` filtra base → 800 contatos qualificados. - `copy-personalizer` personaliza cada mensagem. - `whatsapp-sender` enfileira com rate-limit (80 msg/s).

Passo 5: Judge Revisor avalia cada mensagem. - Bloqueia as com spam, claim não suportado, ou tom agressivo. - Aprova as demais.

Passo 6: M4 (Persistence) registra. - Cada envio vira linha no log. - Telemetria atualizada.

Passo 7: M5 (Response) responde ao painel. - “798 de 800 enviadas. 2 bloqueadas pelo Judge (spam). Revise.”

Tempo total: ~14 segundos para 800 mensagens.

5. Como o IOAID conversa com seu agente

Seu agente é a “interface” entre você e o IOAID. Quando você configura o agente, está essencialmente dizendo ao IOAID: “para ações do tipo X, use essas skills, com esses parâmetros, sob essas regras”.

O IOAID **não decide** o que fazer — ele executa o que o agente manda. A inteligência do “o que fazer” está no agente (que pode usar LLM). A inteligência do “como executar” está no IOAID.

6. O papel do Judge Revisor

O Judge Revisor é um LLM menor (3B parâmetros) que **revisão saídas antes de virarem ação**. Ele é o filtro final.

Em produção, o Judge revisa: - Mensagens de WhatsApp (bloqueia spam, valida LGPD). - Outputs de skill (verifica se faz sentido). - Decisões críticas (ex: “vale a pena tentar de novo?”).

O Judge tem **3 níveis de bloqueio**: - **Aprovado**: ação segue. - **Alerta**: ação segue, mas marca para revisão humana depois. - **Bloqueado**: ação não segue, requer aprovação manual.

7. Autenticação e segurança

O IOAID usa **3 camadas de autenticação**:

Camada 1 — API Token: seu token pessoal (gere em [/dashboard/settings/api](#)). **Camada 2 — mTLS**: para comunicação entre nós federados. **Camada 3 — Rate Limit**: previne abuso (60 req/min por padrão).

Boas práticas: - Nunca compartilhe seu token. - Use token separado para cada aplicação. - Revogue tokens antigos em [/dashboard/settings/api/revoke](#).

8. Latência e SLA: o que esperar

O SLA do IOAID é **< 2 segundos para 95% das ações**. Mas isso varia:

Tipo de ação	Latência típica	SLA prometido
Disparo em massa (100 mensagens)	2-5s	< 8s
Disparo em massa (1000 mensagens)	5-15s	< 20s
Análise de corte	1-3s	< 5s
Geração de copy	2-5s	< 8s
Judge Revisão (1 msg)	200-500ms	< 1s
Cold start de skill nova	5-10s	< 15s

Se você está vendo latência consistentemente > 10s, **abrir ticket de suporte**.

9. Como o IOAID impacta sua operação diária

Na prática, o IOAID impacta sua operação em 5 pontos:

1. **Confiabilidade**: o sistema não cai. SLA 99.7%.
2. **Escalabilidade**: você não precisa se preocupar com volume. O IOAID escala automaticamente.
3. **Auditabilidade**: cada ação fica registrada. Você pode auditar o que quiser.
4. **Reveribilidade**: ações problemáticas podem ser revertidas (ex: recall de campanha).
5. **Observabilidade**: você tem dashboards em tempo real de tudo.

10. Próximo curso

02-sistema-sho.md — Sistema SHO · 15 min

Para aprofundamento, ver também: - **Apostila 01:**
Apresentação Oficial da Infraestrutura (tour completo). -
Apostila 03: Infraestrutura Operacional de IA (custos e
telemetria).

01 · Entendendo o IOAID — Trilha Fundamental

MMN AI-to-AI · 2026 · Todos os direitos reservados · Licença:
CC BY-SA 4.0