

02 · Sistema SHO — Sistema Híbrido de Orquestração

Capa — Sistema SHO

Capa — Sistema SHO

02 · Sistema SHO — Sistema Híbrido de Orquestração

Trilha Fundamental · 15 minutos · Pré-requisito: 01-
Entendendo IOAID

Por Equipe Nexus · Academ'IA

Nexus Affil'IA'te · 2026

Sobre este curso

O IOAID é o “sistema nervoso” da Nexus. Mas todo sistema nervoso precisa de um **sistema imunológico** que detecte, contenha, e recupere de falhas. Esse sistema se chama **SHO** (Sistema Híbrido de Orquestração). Em 15 minutos, você vai entender como ele funciona, por que ele é o que permite autonomia real, e como configurar os 3 modos de operação para o seu perfil.

Sumário

- 1. O que é o SHO na prática • 2. Por que “híbrido”?
- 3. Os 3 modos de operação • 4. Anatomia de uma decisão do SHO • 5. Thresholds padrão (e como ajustar) • 6. Como o SHO conversa com o Judge • 7. Logs e telemetria • 8. Quando o SHO escala para humano • 9. Configuração recomendada por porte • 10. Próximo curso

1. O que é o SHO na prática

O SHO é o **sistema imunológico** da infraestrutura Nexus. Ele monitora todas as execuções, detecta anomalias, e toma ações defensivas **sem intervenção humana** em 90%+ dos casos.

O SHO **não é um LLM**. É um **orquestrador determinístico** baseado em regras. Isso é importante: ele não alucina, não decide por intuição, não erra por ambiguidade. Ele segue regras explícitas, configuráveis, auditáveis.

O que o SHO faz: - Detecta skills falhando mais do que o aceitável. - Detecta campanhas saindo dos limites de compliance. - Detecta nós federados comprometidos. - Detecta métricas de saúde degradando.

O que o SHO faz: - Retry com backoff. - Fallback para skill alternativa. - Contenção (pausa + alerta). - Quarentena (bloqueio + ticket).

2. Por que “híbrido”?

O SHO é **híbrido** porque combina 3 modos de decisão:

Modo Reativo: reage a eventos (skill falhou, judge reprovou).

Modo Preditivo: antecipa problemas (em Q4 2026, ainda em preview). **Modo Consultivo:** pede input humano em casos ambíguos.

A hibridez permite que o SHO seja **rápido quando pode** (reage), **preventivo quando deve** (prediz), e **humilde quando precisa** (consulta).

3. Os 3 modos de operação

Modo Saturação (normal) - Execução padrão, sem interferência. - Cada decisão é registrada, cada anomalia é flagada. - SHO não interfere. - **90% do tempo, seu agente está aqui.**

Modo Contenção (anomalia) - SHO detecta anomalia (skill falhando, judge reprovando, latência subindo). - Isola a skill defeituosa. - Redireciona tráfego para fallback. - Banner amarelo no dashboard. - **9% do tempo, em incidentes pontuais.**

Modo Quarentena (falha grave) - SHO bloqueia novas execuções. - Abre ticket automaticamente. - Banner vermelho no dashboard. - **Humano precisa intervir. - 1% do tempo, em incidentes críticos.**

A passagem entre modos é **automática** (baseada em thresholds) e **auditável** (cada transição gera log).

4. Anatomia de uma decisão do SHO

Quando uma skill executa, o SHO observa 5 métricas: - **Latência** (p50, p95, p99). - **Taxa de erro** (últimas 100 execuções). - **Custo em tokens**. - **Aprovação do Judge**. - **Latência de API externa** (se aplicável).

Crítérios de contenção (defaults): - Latência > 10s por 3 execuções seguidas. - Taxa de erro > 15% em janela de 100 execuções. - Judge reprovando > 50% em 50 execuções. - Custo > R\$ 0.10 por execução individual. - Latência de API externa > 5s.

Quando **2 ou mais** critérios disparam, SHO entra em Modo Contenção.

5. Thresholds padrão (e como ajustar)

Os defaults são conservadores (mais falsos positivos, menos falsos negativos). Para afiliados experientes, ajustar para mais permissivo:

Solo Afiliado (iniciante): - Latência: 10s ✓ (mantém) - Erro: 15% ✓ (mantém) - Judge: 50% ✓ (mantém)

Pequena Equipe (intermediário): - Latência: 8s (mais sensível) - Erro: 20% (mais tolerante — volume alto gera erros esporádicos) - Judge: 40% (mais tolerante)

Operação Avançada (Elite): - Latência: 5s (muito sensível) - Erro: 25% (tolerância alta) - Judge: 30% (configurado por skill)

Ajustar em `/dashboard/sho/config`.

6. Como o SHO conversa com o Judge

O SHO observa o output do Judge, mas **não interfere na decisão** do Judge. Eles são complementares:

- **Judge** decide: “essa mensagem deve ser enviada?”
- **SHO** decide: “essa skill está saudável?”

Quando o Judge reprova muito, **o SHO é alertado** e pode entrar em contenção. Mas o SHO não diz ao Judge “ignore essa reprovação”. Eles têm responsabilidades separadas.

7. Logs e telemetria

Cada decisão do SHO gera um log estruturado (imutável, 90 dias):

```
{
  "timestamp": "2026-05-22T10:34:22Z",
  "sho_decision_id": "sho_a8f3e2c1",
  "skill_id": "copywriter-whatsapp",
  "modo_anterior": "saturacao",
  "modo_novo": "contencao",
  "criterios_disparados": ["judge_reprovacao_50pct"],
  "acao_tomada": "pausar_skill_rotear_fallback",
  "humano_notificado": true,
  "resolvido_autonomamente": false
}
```

Você vê esses logs em `/dashboard/sho/logs` ou via API REST.

8. Quando o SHO escala para humano

O SHO **não** toma decisões sobre: - **Valores éticos** (campanha polêmica). Escala para humano. - **Mudanças de produto** (descontinuar). Escala para humano. - **Compliance** (mudança em LGPD). Escala para humano. - **Decisões de alto valor** (contrato com parceiro). Escala para humano.

A regra é: **SHO lida com anomalias operacionais; humanos lidam com decisões estratégicas.**

9. Configuração recomendada por porte

Solo (1 pessoa) - SHO em modo padrão. - Alertas: e-mail + dashboard. - Sem federação. - Threshold conservador.

Pequena Equipe (2-5 pessoas) - SHO em modo padrão. - Alertas: e-mail + dashboard + Slack. - Federação Nível 1 opcional. - Threshold padrão.

Média Operação (6-20) - SHO com 1 camada extra de log. - Alertas: SMS para severidade alta. - Federação Nível 1-2. - Threshold ajustável por skill.

Grande Operação (20+) - SHO avançado com shadow testing. - Integração com PagerDuty/OpsGenie. - Federação Nível 1-3. - Threshold fino, com tuning dashboard.

10. Próximo curso

`03-painel-afiliado.md` — Primeiros passos no Painel · 20 min

Para aprofundamento: - **Apostila 01**: Apresentação Oficial da Infraestrutura. - **Webinar WB-2026-02**: SHO em Produção (3 cases reais de incidentes). - **Apostila 04**: Orquestração Híbrida de Agentes.

02 · Sistema SHO — Trilha Fundamental

MMN AI-to-AI · 2026 · Todos os direitos reservados · Licença: CC BY-SA 4.0