

WB-2026-02 · SHO em Produção

2026-05-22

Capa — SHO em Produção

Capa — SHO em Produção

WB-2026-02 · SHO em Produção

Webinar expandido em apostila — o Self-Healing Orchestrator
em ambiente de produção real

Palestrante: Eng. SHO + Estrategista convidado **Data**

original: 22/05/2026 · **Duração:** 75 min

Nexus Affil'IA'te · 2026

Sobre esta apostila

Esta é a versão expandida do webinar WB-2026-02. O webinar original apresentou o SHO (Self-Healing Orchestrator) em ambiente de produção, com 3 cases reais de incidentes resolvidos autonomamente. Esta apostila documenta o conteúdo técnico em profundidade, com os protocolos, os logs reais, e as lições aprendidas.

Sumário

- 1. O que é o SHO na prática • 2. Os 3 modos de operação • 3. Anatomia de uma decisão do SHO • 4. Case 1 — Resiliência de skill de copy • 5. Case 2 — Contenção de campanha problemática • 6. Case 3 — Quarentena de nó federado • 7. Configuração recomendada por porte • 8. Logs e telemetria • 9. Limites e quando escalar para humano • 10. Q&A completo

1. O que é o SHO na prática

O SHO (Self-Healing Orchestrator) é o **sistema imunológico** da infraestrutura Nexus. Ele monitora todas as execuções, detecta anomalias, e toma ações defensivas **sem intervenção humana** em 90%+ dos casos.

O SHO não é um LLM. É um **orquestrador determinístico** baseado em regras. Ele sabe: - Quando uma skill está falhando mais do que o aceitável. - Quando uma campanha está saindo dos limites de compliance. - Quando um nó federado está comprometido. - Quando uma métrica de saúde degrada.

E ele age: retry, fallback, contenção, quarentena.

2. Os 3 modos de operação

Modo Saturação (normal) - Execução padrão. - Cada decisão é registrada, cada anomalia é flagada. - SHO não interfere.

Modo Contenção (anomalia detectada) - SHO isola a skill defeituosa. - Redireciona tráfego para fallback. - Alerta: amarelo no dashboard.

Modo Quarentena (falha grave) - SHO bloqueia novas execuções. - Abre ticket de suporte automaticamente. - Alerta: vermelho no dashboard. - **Humano precisa intervir.**

A passagem entre modos é **automática**, baseada em thresholds configuráveis.

3. Anatomia de uma decisão do SHO

Quando uma skill executa, o SHO observa: - Latência (p50, p95, p99). - Taxa de erro (últimas 100 execuções). - Custo em tokens. - Aprovação do Judge. - Latência de rede (em chamada a APIs externas).

Critérios de contenção (configurável, defaults razoáveis): - Latência > 10s por 3 execuções seguidas. - Taxa de erro > 15% em janela de 100 execuções. - Judge reprovando > 50% em janela de 50 execuções. - Custo > R\$ 0.10 por execução individual. - Latência de API externa > 5s.

Quando **2 ou mais** critérios disparam, SHO entra em **Modo Contenção**.

4. Case 1 — Resiliência de skill de copy

Incidente: Em 18/04/2026, a skill `copywriter-whatsapp` começou a retornar mensagens com tom agressivo após uma atualização do LLM subjacente.

Detecção: SHO notou que o Judge começou a reprovar 47% das mensagens (vs. baseline de 6%). Threshold: > 30% em 50 execuções = contenção.

Ação do SHO: 1. Marcou a skill como suspeita. 2. Pausou novas execuções. 3. Roteou execuções para a skill `copywriter-email` (fallback configurado), com adaptação automática de tom (de email para WhatsApp). 4. Abriu ticket de prioridade média.

Resolução humana: 2 horas. Equipe técnica reverteu a versão do LLM. SHO validou a correção (Judge voltou a reprovar < 10%) e promoveu a versão estável.

Impacto: zero mensagens problemáticas chegaram a leads. 100% dos disparos foram roteados para fallback.

5. Case 2 — Contenção de campanha problemática

Incidente: Em 03/05/2026, um afiliado configurou uma campanha de reativação de frios, mas a coorte estava com 90% de números banidos/inválidos.

Detecção: SHO notou que a taxa de falha de entrega subiu de 2% para 38% em 15 minutos.

Ação do SHO: 1. Pausou a campanha. 2. Alertou o afiliado (banner amarelo). 3. Sugeriu limpar a base via skill `audience-segmenter` (regra: remover inválidos). 4. Não abriu ticket (era erro de configuração, não bug).

Resolução humana: 12 minutos. Afiliado limpou a base, re-aprovou a campanha. SHO validou a entrega > 95% e re-ativou.

Impacto: 1 campanha pausada preventivamente. 0 leads receberam mensagem com erro.

6. Case 3 — Quarentena de nó federado

Incidente: Em 11/05/2026, um nó federado começou a fazer chamadas suspeitas (volume 50x o normal, IPs em geolocalização inesperada).

Detecção: SHO notou anomalia no padrão de uso (volume + latência + IP).

Ação do SHO: 1. Quarentenou o nó (bloqueou novas requisições). 2. Manteve consultas para preservar estado. 3. Abriu ticket de prioridade ALTA. 4. Notificou administrador da rede.

Resolução humana: 4 horas. Verificou-se que o nó tinha sido comprometido (credenciais vazadas). Foi feita rotação de mTLS, auditoria de logs, e re-ativação supervisionada.

Impacto: 0 dados vazaram. O isolamento evitou propagação para outros nós da federação.

7. Configuração recomendada por porte

Solo Afiliado (1 pessoa) - SHO em modo padrão. - Alertas: e-mail + dashboard. - Sem federação. - Threshold de contenção: conservador.

Pequena Equipe (2-5 pessoas) - SHO em modo padrão. - Alertas: e-mail + dashboard + Slack. - Federação opcional (Nível 1). - Threshold de contenção: padrão.

Média Equipe (6-20 pessoas) - SHO em modo com 1 camada extra de log. - Alertas: e-mail + dashboard + Slack + SMS (apenas severidade alta). - Federação Nível 1-2. - Threshold de contenção: ajustável por skill.

Grande Operação (20+ pessoas) - SHO em modo avançado com shadow testing. - Alertas: integração com PagerDuty/OpsGenie. - Federação Nível 1-3. - Threshold de contenção: fino, com dashboards de tuning.

8. Logs e telemetria

Cada decisão do SHO gera um log estruturado:

```
{
  "timestamp": "2026-05-22T10:34:22Z",
  "sho_decision_id": "sho_a8f3e2c1",
  "skill_id": "copywriter-whatsapp",
  "modo_anterior": "saturacao",
  "modo_novo": "contencao",
  "criterios_disparados": ["judge_reprovacao_50pct"],
  "acao_tomada": "pausar_skill_rotar_fallback",
  "fallback_usado": "copywriter-email",
  "humano_notificado": true,
  "resolvido_autonomamente": false,
  "duracao_contencao_ms": 7200000
}
```

Esses logs são **imutáveis** (append-only) e ficam disponíveis por 90 dias para auditoria.

9. Limites e quando escalar para humano

O SHO **não** toma decisões sobre: - **Valores éticos** (ex: campanha polêmica). Escala para humano. - **Mudanças de produto** (ex: descontinuar). Escala para humano. - **Compliance** (ex: mudança em LGPD). Escala para humano. - **Decisões de alto valor** (ex: contrato com parceiro). Escala para humano.

A regra é: **SHO lida com anomalias operacionais; humanos lidam com decisões estratégicas.**

10. Q&A completo

P1: Posso desativar o SHO? R: Pode, mas não recomendamos. Sem SHO, falhas propagam. 99% dos afiliados deixa ativado.

P2: SHO decide sozinho se a mensagem é spam? R: SHO detecta padrões (volume, frequência, taxa de bloqueio). O **Judge** é quem avalia o conteúdo.

P3: Quanto custa o SHO? R: Está incluso no plano. Não há cobrança adicional.

P4: SHO tem alucinações? R: SHO é determinístico, baseado em regras. Não tem LLM. Não alucina.

P5: Como configuro o threshold de contenção? R: Em `/dashboard/sho/config`. Sugerimos começar com defaults e ajustar após 30 dias de operação.

P6: SHO pode entrar em loop? R: SHO tem proteções anti-loop (circuit breaker). Se o SHO entra em contenção e a contenção não resolve em 1h, escala para humano.

P7: Como exporto logs do SHO? R: Via API REST (`/api/v1/sho/logs?start=...&end=...`) ou download CSV em `/dashboard/sho/export`.

P8: SHO monitora custos? R: Sim. SHO pode pausar execução se o custo diário da skill ultrapassar 80% do orçamento configurado.

P9: Como o SHO se comunica com o Judge? R: Via canal interno. SHO observa o output do Judge; Judge é independente na decisão de aprovar/reprovar.

P10: SHO funciona em federação? R: Sim. SHO monitora também chamadas entre nós federados. Anomalias em 1 nó disparam contenção só local (não derrubam a federação inteira).

WB-2026-02 · SHO em Produção — Versão Apostila
Expandida

MMN AI-to-AI · 2026 · Todos os direitos reservados · Licença:
CC BY-SA 4.0