

--- title: "WB-2026-06 · A/B Testing Estatístico: Como Não Ser Enganado pelos Seus Próprios Dados" level: "master" duracao: "90-120min" data: "2026-08-12" formato: "webinar-ao-vivo + gravado" palestrante: "Equipe Nexus + 2 estatísticos convidados" tags: [ab-test, estatistica, confianca, armadilhas] pattern: "MMN_IA" status: "planejado" --- ![Capa — A/B Testing Estatístico](../docs/ebooks/ACAD-apostila-07-18-skills-operacionais.webp)

WB-2026-06 · A/B Testing Estatístico: Como Não Ser Enganado pelos Seus Próprios Dados

O guia anti-bobagem para testes A/B. Por que 80% dos "vencedores" são falsos positivos, e como evitar tomar decisões erradas baseado em dados ruins.

Por Equipe Nexus · Academ'IA

Nexus Affil'IA'te · 2026

Sobre este webinar

A/B testing parece simples: testa A vs B, vê qual converte mais, escolhe o vencedor. Mas 80% das pessoas que fazem A/B testing em marketing cometem **erros estatísticos** que invalidam o resultado. Neste webinar, **2 estatísticos profissionais** vão desmascarar as armadilhas mais comuns e dar o framework correto.

--- # Sumário

- 1. Por que A/B testing é perigoso
- 2. Os 2 convidados (estatísticos)
- 3. O caso clássico: botão verde vs azul
- 4. Erro 1 — Parar cedo demais (peeking)
- 5. Erro 2 — Testar muitas variantes ao mesmo tempo
- 6. Erro 3 — Ignorar variância temporal
- 7. Erro 4 — Confundir correlação com causalidade
- 8. Erro 5 — Não calcular poder estatístico
- 9. Framework correto em 5 passos
- 10. Q&A ao vivo

1. Por que A/B testing é perigoso

A/B testing é, em teoria, a forma mais "científica" de tomar decisão em marketing. Você testa, mede, escolhe. Na prática, **é onde mais gente toma decisões erradas**. Por 3 motivos:

- Estatística é difícil** — 90% dos marqueteiros não entendem p-value, poder estatístico, ou intervalo de confiança.
- Ferramentas escondem a complexidade** — plataformas mostram "vencedor" após 100 visitas, mas 100 visitas **não é estatisticamente significativo**.
- O instinto quer parar cedo** — quando você vê uma variante "vencendo" por 30%, a tentação é parar e implementar. Mas isso é **peeking**, e é o erro mais comum.

Resultado: 80% dos "vencedores" em A/B testing de marketing são **falsos positivos**.

2. Os 2 convidados

Dr. Pedro Sávio, 47 anos, São Paulo - Estatístico PhD pela USP - Trabalhou 12 anos no Google, liderando experimentos de busca - Hoje consultor de A/B testing para 14 empresas (incluindo Nubank, iFood) - Publicou "A/B Testing for Humans" (2024)

Dra. Mariana Ribeiro, 39 anos, Recife - Estatística PhD pela UFPE - Trabalhou 8 anos no Spotify, na equipe de experimentation - Hoje consultora de growth analytics - Co-autora do paper "The Peeking Problem in Online Experimentation" (2023)

3. O caso clássico: botão verde vs azul

Uma loja online queria testar: botão "Comprar" verde vs azul. Cenário típico:

- Variante A (verde): 2.3% conversão em 200 visitas = 4.6 conversões
- Variante B (azul): 3.1% conversão em 200 visitas = 6.2 conversões

Reação típica: "B venceu! Vamos implementar azul!"

O que a estatística diz: com 200 visitas por variante, a **diferença não é estatisticamente significativa**. O intervalo de confiança de 95% para B inclui 2.3%. Pode ser que B seja realmente melhor, ou pode ser que os dados foram sorte.

O que fazer: rodar até atingir **poder estatístico de 80%** com **confiança de 95%**. Para detectar uma diferença de 0.8 pontos percentuais (3.1% - 2.3%), você precisa de ~3.500 visitas por variante. **Tempo necessário:** se a loja recebe 100 visitas/dia, são 35 dias de teste. Não 1 dia.

4. Erro 1 —

Parar cedo demais (peeking)** **Peeking** = olhar o resultado do teste várias vezes durante a execução e parar quando "vencedor" aparece. **Por que é errado**: cada "olhada" aumenta a chance de falso positivo. Se você olha 10x durante o teste, a chance de encontrar um "vencedor" por acaso é de ~40%, não 5%. **Como evitar**: defina o tamanho da amostra ANTES de começar. Não pare antes de atingir. Use ferramentas que **escondem** os resultados parciais (ex: Optimizely, VWO). **Caso real**: uma fintech brasileira parou um teste após 3 dias (1.500 visitas) porque B estava "vencendo" por 50%. Migrou 100% dos usuários para B. **Após 30 dias**, A voltou a ficar à frente. Decisão errada custou R\$ 200k. --- **5. Erro 2 — Testar muitas variantes ao mesmo tempo** Testar A, B, C, D, E ao mesmo tempo (5 variantes) **não é o mesmo** que testar A vs B em sequência. **Problema**: com 5 variantes, a chance de falso positivo em algum par é ~20% (vs 5% com 2 variantes). Para corrigir, precisa aplicar **correção de Bonferroni** (dividir p-value por 5). **Recomendação**: máximo 4 variantes por teste (incluindo controle). Para mais, faça testes sequenciais. --- **6. Erro 3 — Ignorar variância temporal** Conversão varia por dia da semana, hora do dia, mês. Um teste de 1 semana pode pegar padrões sazonais errados. **Exemplo**: testar dia 1-7 (quarta a terça). Se a "vitória" foi puxada pelo fim de semana (que naturalmente converte mais), você está confundindo dia da semana com variante. **Recomendação**: teste por **pelo menos 2 ciclos completos** (14 dias mínimo, ideal 28). Use bloqueios por dia/hora se necessário. --- **7. Erro 4 — Confundir correlação com causalidade** A variante B converteu 3.1%, e a A converteu 2.3%. Conclusão típica: "B é melhor". Mas talvez **B atendeu usuários diferentes**. Se B foi mostrado, por acaso, para usuários de São Paulo (que naturalmente convertem mais), a "vitória" de B é **ilusória**. **Como evitar**: use **randomização estratificada** — garanta que cada variante veja o mesmo perfil de usuário. Ou ajuste por covariáveis (cidade, dispositivo, hora) na análise. --- **8. Erro 5 — Não calcular poder estatístico** **Poder estatístico** = probabilidade de detectar uma diferença real, se ela existir. Se seu teste tem 50% de poder, você tem 50% de chance de perder uma vitória real. Isso é "falso negativo". **Como calcular**: precisa de 3 coisas: 1. **Tamanho de efeito mínimo** que importa detectar (ex: 0.5 pontos percentuais) 2. **Variância** da métrica (geralmente desconhecida) 3. **Nível de significância** (típico: 5%) Ferramenta: **Regra prática**: para detectar 10% de lift (B sendo 10% melhor que A) com baseline de 5%, precisa ~3.000 variantes por braço. --- **9. Framework correto em 5 passos** Pedro e Mariana convergem no seguinte framework: `` PASSO 1: HIPÓTESE "Se eu mudar [X], então [Y] vai aumentar [Z]%" Ex: "Se eu trocar CTA verde por azul, conversão vai aumentar 10%" PASSO 2: MÉTRICA PRIMÁRIA Qual é a métrica de sucesso? (conversão? receita? retenção?) Não pode mudar durante o teste. PASSO 3: CÁLCULO DE AMOSTRA Use uma calculadora de poder estatístico. Defina n ANTES de começar. PASSO 4: RANDOMIZAÇÃO Split 50/50 (ou outra proporção) de forma aleatória. Verifique que A e B têm perfis similares (cidade, device, etc). PASSO 5: ANÁLISE Quando atingir n, ANALISE. Não antes. Use intervalo de confiança de 95%. Se intervalo inclui 0% lift, é empate. Reporte: "B converteu X% (CI: [Y%, Z%]). Empate/vitória estatisticamente significativa." `` --- **10. Q&A ao vivo** Os convidados responderão sobre: - Como rodar testes em baixo volume (e.g., 50 visitas/dia) - Quando usar testes sequenciais vs paralelos - Como integrar A/B testing com Judge Revisor - Métricas secundárias

(revenue per user, retention, etc) - Quando parar um teste "perdendo" prematuramente --- # Especificações | Item | Detalhe | |-----|-----| |
Data | 12 de agosto de 2026 | | **Duração** | 90-120 min (60 painel + 30 Q&A) | |
Público-alvo | Alunos da Trilha Master, ou marqueteiros com alguma experiência em A/B | |
Pré-requisito | Curso 02-ab-test-judge.md | |
Gravação | Liberada 48h após | |
Inscrição | R\$ 97 (grátis para membros Nexus) | --- *"A estatística é a forma que a matemática tem de dizer 'calma, não é tão simples quanto parece'. E isso, no marketing, é uma bênção."*
Por MMN AI-to-AI · 2026