

A Revolução dos Modelos de Linguagem

ChatGPT, Gemini, Llama e o futuro da
comunicação com IA

[Capa: Cérebro com texto e ondas de conversa]

Sumário

- 1. O que são LLMs? (2p)
 - 2. Arquitetura Transformer (3p)
 - 3. Principais modelos: GPT, Claude, Llama, Gemini (3p)
 - 4. Engenharia de Prompt (4p)
 - 5. Alucinações e limitações (2p)
 - 6. RAG (Retrieval-Augmented Generation) (2p)
 - 7. Ética e plágio (2p)
 - 8. Agentes autônomos e futuro (2p)
 - 9. Glossário + desafio (2p)
-

1. O que são LLMs?

Large Language Models são redes neurais treinadas com bilhões de palavras. Eles preveem a próxima palavra em uma sequência.

□ Exemplo: GPT-3 foi treinado com 570 GB de textos.

[Ilustração: enorme biblioteca de dados alimentando um cérebro digital]

2. Arquitetura Transformer

Apresentada no paper "Attention is All You Need" (2017). O mecanismo de atenção permite que o modelo foque em partes relevantes do texto.

[Diagrama do Transformer: input embedding → atenção multi-head → feed forward → output]

3. Principais modelos

Modelo	Empresa	Acesso
GPT-4	OpenAI	Pago / API
Claude 3	Anthropic	Grátis/Pago
Gemini	Google	Grátis
Llama 3	Meta	Aberto (open source)

4. Engenharia de Prompt

Técnicas para obter melhores respostas:

- **Zero-shot:** sem exemplos
- **Few-shot:** com 2-3 exemplos
- **Chain-of-Thought:** "pense passo a passo"

[Comparação: prompt ruim vs. prompt otimizado]

5. Alucinações

Modelos de linguagem podem inventar fatos com confiança. Isso é chamado de alucinação.

□ Exemplo: ChatGPT pode criar referências bibliográficas falsas.

6. RAG (Retrieval-Augmented Generation)

RAG combina busca em uma base de dados + geração de texto, reduzindo alucinações e permitindo respostas atualizadas.

[Fluxo: Pergunta → busca vetorial → contexto + LLM → resposta]

7. Ética e plágio

LLMs podem reproduzir textos protegidos por direitos autorais. Além disso, perpetuam vieses dos dados de treino.

8. Agentes autônomos

Futuro: LLMs que controlam ferramentas (navegador, código, APIs) para executar tarefas complexas. Ex: AutoGPT, BabyAGI.

9. Glossário + Desafio

Token: unidade de texto

Context window: limite de tokens

Fine-tuning: ajuste fino

Desafio: Crie um prompt que force o ChatGPT a resolver um problema de lógica usando chain-of-thought.
